

CONTENIDO


1. Análisis	3
2. MAÍZ	5
2.1. Parcelas Estacionales	5
2.2. Gráfica de subseries estacionales	7
2.3. Componente generales de la serie temporal	8
2.3.1. Descomposición por la función <code>decompose()</code> de R	9
2.4. Análisis de correlograma	14
2.4.1. Autocorrelación simple	15
2.4.2. Gráficas de Retraso	17
2.5. Técnicas de suavizado	19
2.5.1. Suavizado de la media móvil centrado	19
2.5.2. Suavizado de la media móvil hacia atrás	22
2.5.3. Suavizado por Método de Holt-Winters	23
2.5.4. Suavizado por la función <code>ETS()</code> de R	25
2.6. Pruebas de Estacionariedad	28
2.6.1. Prueba de Dickey-Fuller aumentada	29
2.6.2. Prueba de Phillips-Perron	30
2.7. ARIMA(p,d,q)	30
2.7.1. Criterios de Información	31
2.8. SARIMA(p,d,q)(P,D,Q)[m]	32
2.8.1. Correlograma <i>ACF</i> y <i>PACF</i> del modelo ARIMA(1,0,0)	32
2.8.2. Criterios de Información	33
2.8.3. Diagnostico del modelo SARIMA(1,1,1)(1,1,1)[12]	35
2.8.4. Gráfico de Raíces Unitarias	36
2.8.5. Pruebas de Normalidad	39
2.8.6. Contraste de normalidad con Q-Q plot	41
2.9. Pronósticos	42
2.9.1. Predicción usando la función <code>ETS()</code> de R	42
2.9.2. Predicción usando Holt Winter	44
2.9.3. Predicción usando <code>Auto.Arima()</code>	45
2.9.4. Predicción usando SARIMA(1,1,1)(1,1,1)[12]	47
2.9.5. Gráfica de los pronósticos	52

```
## Loading required package: xts
## Loading required package: zoo
##
## Attaching package: 'zoo'
## The following objects are masked from 'package:base':
##
##      as.Date, as.Date.numeric
## Loading required package: TTR
## Registered S3 method overwritten by 'quantmod':
##      method           from
##      as.zoo.data.frame zoo
##
## Attaching package: 'dplyr'
## The following objects are masked from 'package:xts':
##
##      first, last
## The following objects are masked from 'package:stats':
##
##      filter, lag
## The following objects are masked from 'package:base':
##
##      intersect, setdiff, setequal, union
```

1. Análisis

Realizando un histograma de frecuencias absolutas (La tabla dada ya pasó por un filtrado en donde se quedan con los 5 productos con mayor volumen de carga) para ver cuales son los 5 productos con mayor volumen de carga.

Los 5 productos con mayor Toneladas Netas de Enero/2014 a Febrero/202



En la cual podemos observar que los productos con mayor volumen de carga ordenados de forma descendente quedan de la siguiente manera:


- Maíz con 127,061,018
- Cemento con 95,856,381
- Contenedores con 73,492,892
- Mineral de Fierro con 64,945,578
- Láminas, Planchas de Fierro y Acero con 59,198,637

Haciendo el mismo histograma de frecuencias absolutas con la diferencia de que ahora vamos a poner en el histograma el comportamiento del producto respecto a las toneladas netas transportadas año con año.

```
## [1] "MAÍZ"
## [2] "CEMENTO"
## [3] "CONTENEDORES"
## [4] "MINERAL.DE.FIERRO"
## [5] "LÁMINAS.Y.PLANCHAS.DE.FIERRO.Y.ACERO"
```

```
## 'summarise()' has grouped output by 'PRODUCTOS'. You can override using the
## '.groups' argument.
```


Desglose de los 5 productos con mayor Toneladas Netas de Enero/2014 a



Dado un análisis previo acerca del comportamiento de los 5 productos con mayor volumen, procedemos a realizar el gráfico de la serie temporal de dichos productos.

Toneladas Netas – Productos


ene. 2014 / feb. 2022




2. MAÍZ

2.1. Parcelas Estacionales

Una **gráfica estacional** es similar a una gráfica de tiempo, excepto que los datos se grafican contra las "estaciones" individuales en las que se observaron los datos. Analicemos la siguiente serie de tiempo.



Ahora de su gráfica estacional, tenemos lo siguiente:




Estos son los mismos datos que se mostraron anteriormente, pero los datos de cada temporada se superponen. Un **gráfico estacional** permite ver más claramente el patrón estacional subyacente y es especialmente útil para identificar los años en los que cambia el patrón.

2.2. Gráfica de subseries estacionales

Una gráfica alternativa que enfatiza los patrones estacionales es donde los datos de cada temporada se recopilan juntos en mini gráficas de tiempo separadas.

Una gráfica de sub-serie estacional faceta la serie temporal por cada estación en el período estacional. Esta faceta forman gráficos de series de tiempo más pequeños que consisten en datos solo de esa temporada. Si tuviera varios años de datos (mensuales, trimestrales, diarios, anuales, etc), el gráfico resultante mostraría un gráfico de serie de tiempo separado por cada período (ya sea mes, año, días) que se este trabajando la serie de tiempo.



Las líneas horizontales azules indican las medias de cada mes. Esta forma de gráfico permite ver claramente el patrón estacional subyacente y también muestra los cambios en la estacionalidad a lo largo del tiempo. Es especialmente útil para identificar cambios dentro de estaciones particulares. Notemos que la serie de tiempo está dada en forma mensual, es por eso que hace un gráfico estacional separado por mes.

2.3. Componente generales de la serie temporal

Al describir las series temporales, podremos encontrar palabras como "tendencia" y "estacionalidad", las cuales se definen de la siguiente manera:

- **Tendencia:** Una *tendencia* existe cuando hay un aumento o disminución a largo plazo en los datos. No tiene que ser lineal. A veces nos referiremos a una tendencia como "cambio de dirección", cuando podría pasar de una tendencia creciente a una tendencia decreciente.
- **Estacional:** Un patrón *estacional* ocurre cuando una serie de tiempo se ve afectada por factores estacionales como la época del año o el día de la semana. La estacionalidad es siempre de un período fijo y conocido.

- **Cíclico:** Un *ciclo* ocurre cuando los datos exhiben subidas y bajadas que no tienen una frecuencia fija. Estas fluctuaciones generalmente se deben a las condiciones económicas y, a menudo, están relacionadas con el "ciclo económico".

Mucha gente confunde el comportamiento cíclico con el comportamiento estacional, pero en realidad son bastantes diferentes. Si las fluctuaciones no son de una frecuencia fija entonces son cíclicas; si la frecuencia no cambia y está asociada con algún aspecto del calendario, entonces el "patrón es estacional". En general, la duración media de los ciclos es mayor que la duración de un patrón estacional. y las magnitudes de los ciclos tienden a ser más variables que las magnitudes de los patrones estacionales. Muchas series de tiempo incluyen tendencia, ciclos y estacionalidad. Al elegir un método de pronóstico, primero necesitaremos identificar los patrones de series de tiempo en los datos y luego elegir un método que pueda capturar los patrones correctamente.

Si asumimos una **descomposición aditiva**, entonces podemos escribir:

$$y_t = S_t + T_t + R_t$$

Donde:

- y_t son los datos.
- T_t es el componente de ciclo de tendencia.
- R_t es el comportamiento restante.

todo en el período t . Alternativamente, una **descomposición multiplicativa** se escribiría como:

$$y_t = S_t \cdot T_t \cdot R_t$$

La **descomposición aditiva** es la más adecuada si la magnitud de las fluctuaciones estacionales, o la variación en torno a la tendencia-ciclo, no varía con el nivel de la serie temporal. Cuando la variación alrededor del ciclo tendencia, parece ser proporcionada al nivel de la serie temporal, entonces es más apropiada una **descomposición multiplicativa**. Las descomposiciones multiplicativas son comunes con las series temporales económicas.

Una alternativa al uso de una descomposición multiplicativa es primero transformar los datos hasta que la variación en la serie parezca estable a lo largo del tiempo y luego usar una descomposición aditiva. Cuando se ha usado una transformación logarítmica, esto es equivalente a usar una descomposición multiplicativa porque:

$$y_t = S_t \cdot T_t \cdot R_t \text{ es equivalente a } \log y_t = \log S_t + \log T_t + \log R_t$$

Visualizando de mejor manera las diferencias entre los componentes que integran la serie de tiempo (MAIZ), hacemos lo siguiente:

2.3.1. Descomposición por la función `decompose()` de R

Utilizando la función `decompose()` en tipo aditiva de R , tenemos lo siguiente:

```
## $x
##           Jan           Feb           Mar           Apr           May           Jun           Jul
## 2014 1037733.6  841936.6  968867.5 1061894.8 1046361.4 1220890.4 1109470.9
## 2015  916324.4  803495.1 1055547.1 1216488.3 1481237.2 1708447.4 1394690.7
## 2016 1151765.0 1192223.4 1269109.9 1296962.5 1522123.0 1579058.8 1458302.9
## 2017 1094419.1  952764.9 1077635.7 1190780.7 1410637.8 1777352.4 1397730.8
## 2018 1197400.4  939691.1  995145.6 1361005.3 1645195.0 1558841.7 1589994.9
## 2019 1298361.2 1213312.8 1202920.1 1230037.4 1453447.6 1520640.7 1634203.5
## 2020 1086484.4 1130574.9 1365206.0 1211035.2 1567916.6 1529451.7 1511977.6
## 2021 1177533.1 1043996.2 1467083.3 1321736.0 1563662.3 1728951.7 1435664.5
## 2022 1410967.6 1118409.3
```

```


##           Aug           Sep           Oct           Nov           Dec
## 2014 1203979.7 1159457.2 906492.2 943968.5 1015504.7
## 2015 1407658.0 1311686.6 1033417.1 1125823.7 1264619.4
## 2016 1467896.1 1363641.1 1065388.9 1273013.8 1080231.7
## 2017 1384385.5 1593865.6 1303444.0 1462605.5 1307751.5
## 2018 1394899.8 1422756.9 1540333.0 1627415.7 1411960.7
## 2019 1498119.5 1351274.6 952244.0 1538732.2 1264958.0
## 2020 1431310.0 1225618.7 1079972.6 1352228.9 1299678.9
## 2021 1575463.4 1335967.8 1343687.9 1540361.6 1454103.5
## 2022
##
## $seasonal
##           Jan           Feb           Mar           Apr           May           Jun
## 2014 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2015 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2016 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2017 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2018 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2019 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2020 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2021 -175772.15 -272243.42 -110278.25 -57445.89 195855.23 298055.28
## 2022 -175772.15 -272243.42
##           Jul           Aug           Sep           Oct           Nov           Dec
## 2014 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2015 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2016 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2017 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2018 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2019 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2020 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2021 142349.92 117925.57 59579.84 -165933.68 35511.41 -67603.86
## 2022
##
## $trend
##           Jan           Feb           Mar           Apr           May           Jun           Jul           Aug           Sep
## 2014         NA         NA         NA         NA         NA         NA 1037988 1031327 1033337
## 2015 1138585 1158956 1173785 1185417 1198283 1216240 1236430 1262437 1287532
## 2016 1298412 1303572 1308247 1311744 1319209 1317659 1307587 1295220 1277265
## 2017 1265148 1259145 1265258 1284770 1302588 1319968 1333739 1337485 1333503
## 2018 1353600 1362049 1355357 1358098 1374835 1386045 1394593 1410201 1430259
## 2019 1410682 1416825 1418147 1390665 1362466 1352646 1337693 1325417 1328732
## 2020 1339091 1331214 1323195 1323281 1320832 1314508 1319748 1319935 1320572
## 2021 1347133 1349959 1360564 1376150 1394977 1409250 1425411 1438238      NA
## 2022         NA         NA
##           Oct           Nov           Dec
## 2014 1043390 1067951 1106386
## 2015 1299784 1304840 1301153
## 2016 1264862 1255793 1259410
## 2017 1337159 1354025 1354693
## 2018 1433459 1420013 1410432
## 2019 1334702 1338680 1343816
## 2020 1329429 1333865 1342000
## 2021         NA         NA         NA
## 2022

```

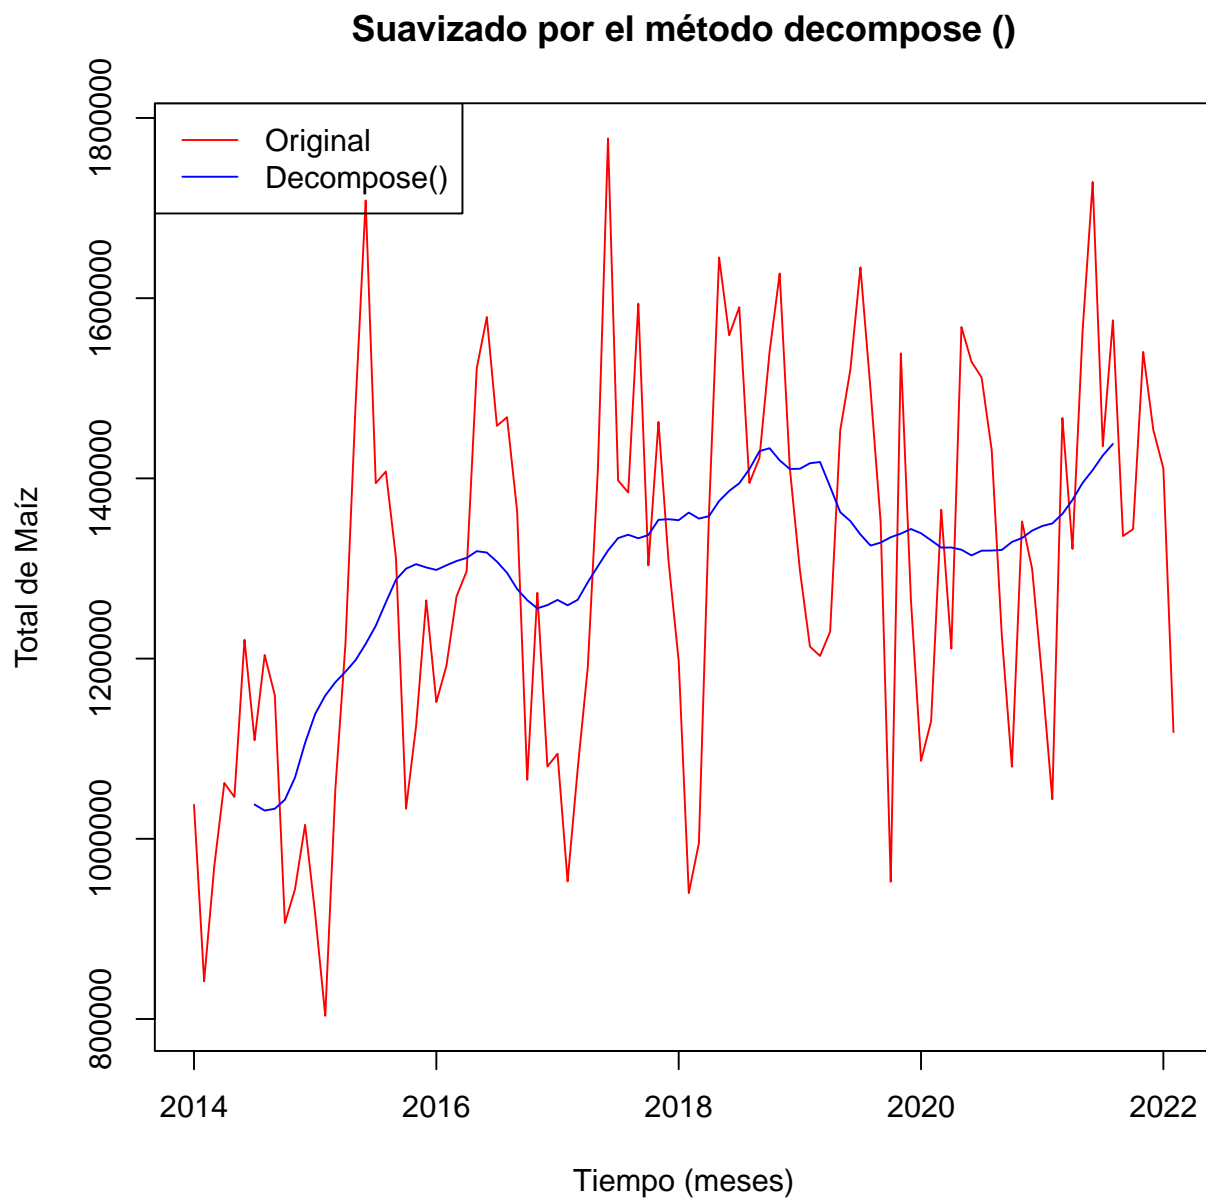
```
##
## $random
##           Jan           Feb           Mar           Apr           May           Jun
## 2014         NA         NA         NA         NA         NA         NA
## 2015 -46488.712 -83217.463  -7960.125   88517.295   87099.295  194152.331
## 2016  29125.142 160894.418   71141.048   42664.294   7058.591  -36655.739
## 2017   5042.958 -34136.454  -77343.886  -36542.956  -87805.617  159329.321
## 2018  19573.031 -150114.041 -249933.313   60353.131   74504.307 -125258.223
## 2019  63451.243  68731.266 -104948.981 -103181.887 -104873.962 -130060.674
## 2020 -76834.059  71604.191  152289.435  -54800.023   51229.127  -83111.463
## 2021   6172.488 -33719.826  216797.913   3032.237  -27169.648   21646.538
## 2022         NA         NA
##           Jul           Aug           Sep           Oct           Nov           Dec
## 2014 -70866.764   54726.886   66540.144   29035.643 -159494.405  -23277.636
## 2015  15911.180   27295.777  -35425.393 -100432.875 -214528.018   31070.598
## 2016   8365.942   54750.344   26796.640  -33539.726  -18290.449 -111574.280
## 2017 -78357.812  -71024.904  200782.761  132219.060   73069.603   20662.268
## 2018   53051.591 -133226.783  -67082.052  272807.279  171891.352   69132.774
## 2019  154160.800   54776.752  -37036.863 -216524.154  164541.241  -11254.446
## 2020   49879.360  -6550.114 -154533.146  -83523.135  -17147.233   25282.814
## 2021 -132096.192   19300.145         NA         NA         NA         NA
## 2022
##
## $figure
## [1] -175772.15 -272243.42 -110278.25  -57445.89  195855.23  298055.28
## [7]  142349.92  117925.57   59579.84 -165933.68   35511.41  -67603.86
##
## $type
## [1] "additive"
##
## attr(,"class")
## [1] "decomposed.ts"
```

El resultado anterior muestra los componentes de una descomposición dada la función *decompose()* de *R*.

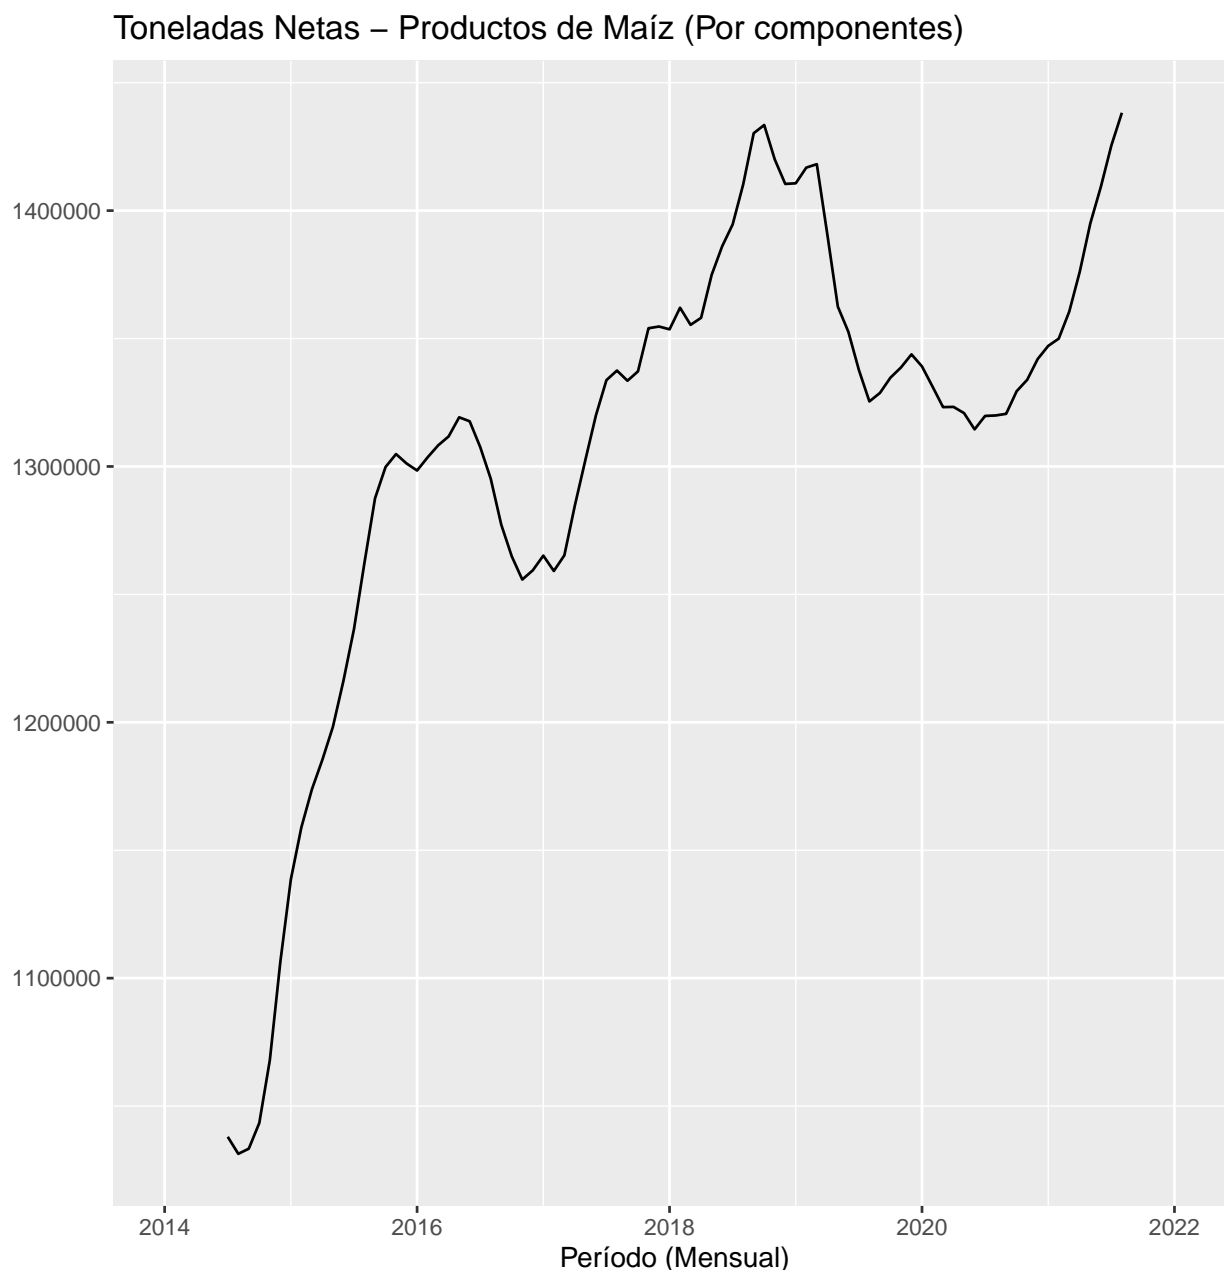
Podemos graficar todos los componentes en una sola figura de la siguiente manera:



La columna **trend** (que contiene la tendencia-ciclo T_t) que sigue el movimiento general de la serie, ignorando cualquier estacionalidad y fluctuaciones aleatorias. Como se muestra en la siguiente gráfica



Podemos comprender a la **tendencia** de la serie de tiempo del maiz como el comportamiento a largo plazo de la serie. Visualizando únicamente la tendencia, tendremos lo siguiente:



Podemos observar que la tendencia tuvo un comportamiento sostenido en la gran parte del periodo, esta también tuvo un importante cambio alrededor de Julio-2016 a Diciembre-2016 y Febrero-2019 a Octubre-2019, donde prácticamente paso de tener un comportamiento creciente a uno decreciente.

2.4. Análisis de correlograma

El análisis del correlograma es una opción que nos ayudará bastante a analizar la interdependencia de los valores de observación. La idea con la que debemos conservar al manejar correlogramas es que sirven para describir la presencia o ausencia de correlación en los datos de las series temporales, indicando si las observaciones pasadas influyen en las actuales.

Ahora veremos la correlación que tienen los datos, es decir, una correlación mide el nivel de semejanza entre una secuencia de hace varios periodos y datos actuales. La secuencia de hace varios periodos atrás se llama retraso.^o "lag" en inglés, porque es una versión retrasada de la original.

Dada una serie de tiempo Y_t , se define su **función de auto-correlación de retraso k** como:

$$\varphi_k(t) = \text{corr}(Y_t, Y_{t-k})$$

Así como la **correlación** mide el alcance de una relación lineal entre dos variables, la **auto-correlación** mide la relación lineal entre los *valores rezagados* de una serie de tiempo. Hay varios coeficiente de autocorrelación, correspondientes a cada panel en el gráfico de retardo, es decir, $\varphi_k(t) = \text{corr}(y_t, y_{t-k})$.

Por ejemplo:

- $\varphi_1(t)$ mide la relación entre y_1 y y_{t-1} .
- $\varphi_2(t)$ mide la relación entre y_t y y_{t-2} , y así sucesivamente.

El valor de $\varphi_k(t)$ se puede escribir como

$$\varphi_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

donde T es la duración de la serie temporal. Los coeficientes de autocorrelación componen la *función de autocorrelación* o *ACF*


Las dos funciones de **auto-correlación** que podemos manejar en los pronósticos de Series de Tiempo son:

1. **Función de Auto-correlación simple:** Mide la autocorrelación entre dos variables separadas por k períodos, o , en otras palabras, el grado de asociación lineal que existe entre dos variables del mismo proceso aleatorio.
2. **Función de Auto-Correlación parcial:** Mide la auto-correlación entre dos variables separadas k períodos cuando no se considera la precedencia de la dependencia creada por los retardos intermedios que hay entre ambas. En otras palabras, esta encuentra la auto-correlación que existe entre dos variables separadas k períodos descontando los posibles efectos debidos a las variables intermedias.

2.4.1. Autocorrelación simple

En seguida se darán los valores y el gráfico de las auto-correlaciones simples del Maiz

Auto-Correlación Simple del Maiz



```
##
## Autocorrelations of series 'ts(Maiz_ts)', by lag
##
##      0      1      2      3      4      5      6      7      8      9     10
## 1.000 0.608 0.359 0.157 -0.032 -0.088 -0.058 -0.115 -0.079 0.039 0.210
## 11     12     13     14     15     16     17     18     19     20     21
## 0.342 0.547 0.360 0.124 -0.055 -0.135 -0.191 -0.141 -0.184 -0.149 -0.065
## 22     23     24     25     26     27     28     29     30     31     32
## 0.075 0.214 0.353 0.236 0.127 -0.026 -0.101 -0.073 -0.068 -0.126 -0.086
## 33     34     35     36
## -0.039 0.097 0.239 0.314
```

Dado los valores y la gráfica de auto-correlación simple, tenemos que $\varphi_1 = 0.608$ y $\varphi_{12} = 0.547$, es decir, es conveniente "predecir" el futuro ya sea con 1 o 12 retrasos (Entre más cercano a 1 es mejor). Lo anterior lo podremos expresar de la siguiente manera:

$$\varphi_1(t) = \text{corr}(X_t, X_{t-1}) = 0.608$$

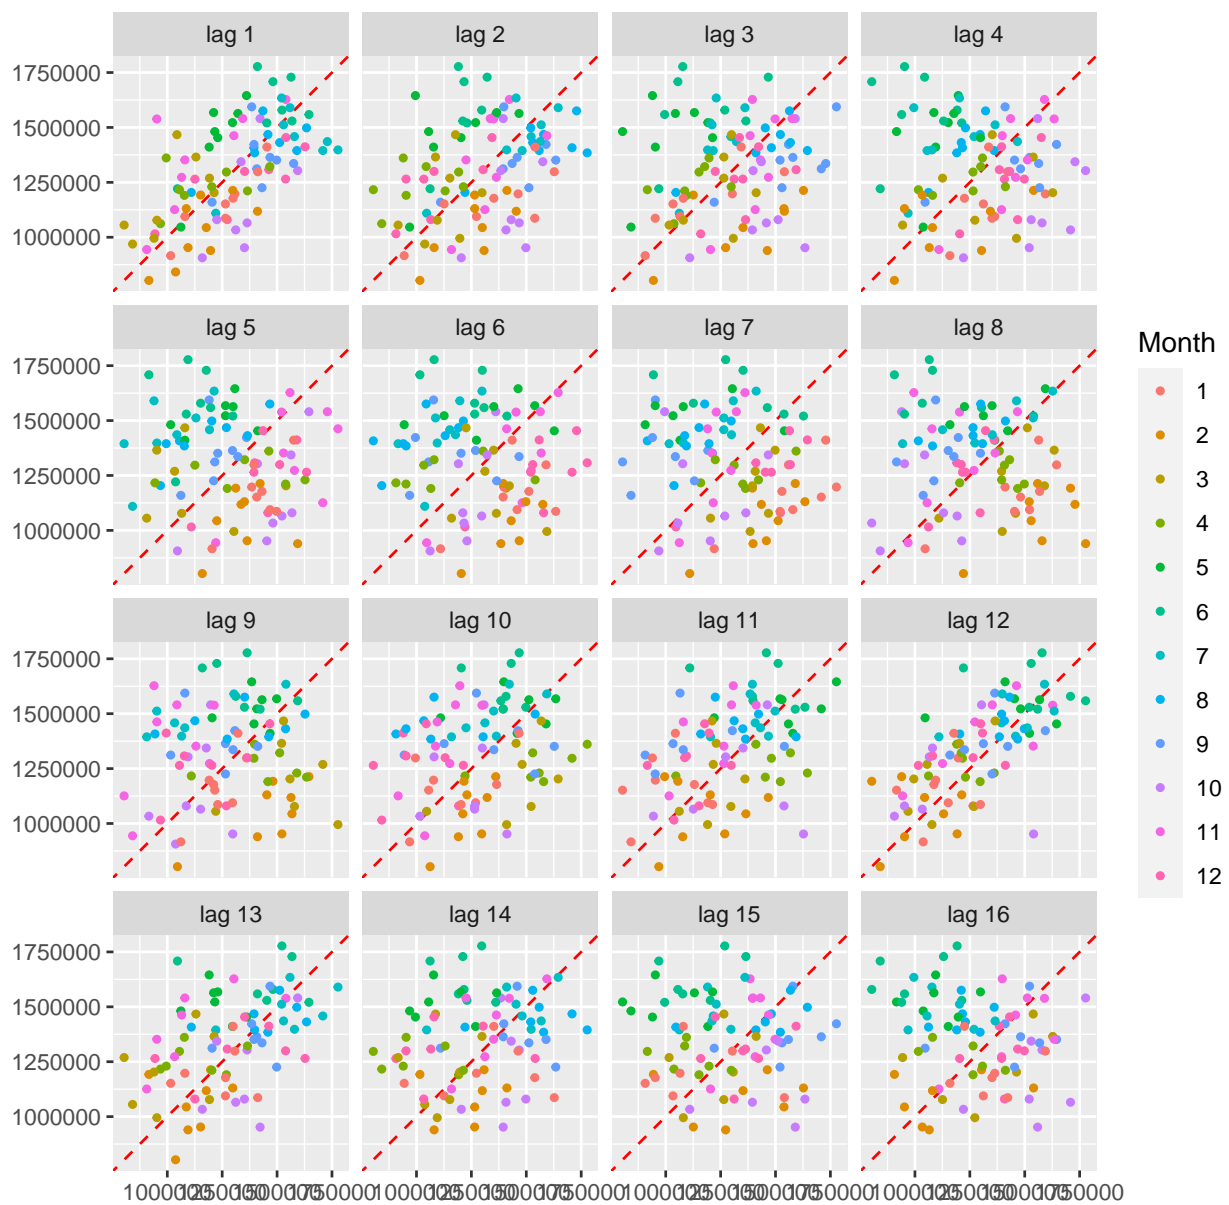
$$\varphi_{12}(t) = \text{corr}(X_t, X_{t-12}) = 0.547$$

Tendencia y estacionalidad en parcelas ACF

- Cuando los **datos tienen una tendencia**, las autocorrelaciones para pequeños retrasos tienden a ser grandes y positivas porque las observaciones cercanas en el tiempo también tienen un valor cercano. Entonces, el *ACF* de una serie de tiempo con tendencia tiende a tener valores positivos que disminuyen lentamente a medida que aumentan los retrasos.
- Cuando los **datos son estacionales**, las auto-correlaciones serán mayores para los retrasos estacionales (en múltiplos de período estacional) que para otros retrasos.
- Cuando los **datos son de tendencia y estacionales**, se ve una combinación de estos efectos.

2.4.2. Gráficas de Retraso

Un gráfico de retraso es un tipo especial de gráfico de dispersión en el que el eje x representa el conjunto de datos con algunas unidades de tiempo atrás o adelante en comparación con el eje y . La diferencia entre estas unidades de tiempo se llama retraso y se representa por k




La relación es fuertemente positiva en el rezago 1 y 12 (φ_1 y φ_{12}) lo que refleja la fuerte estacionalidad de los datos.

Auto-correlación parcial

En seguida se darán los valores y la gráfica de *auto-correlación parcial* del Maiz.

Auto-Correlación Simple del Maiz



```
##
## Partial autocorrelations of series 'ts(Maiz_ts)', by lag
##
##      1      2      3      4      5      6      7      8      9     10     11
## 0.608 -0.017 -0.087 -0.142  0.017  0.066 -0.135  0.032  0.151  0.237  0.134
##     12     13     14     15     16     17     18     19     20     21     22
## 0.345 -0.259 -0.202 -0.116  0.110 -0.046  0.003 -0.096  0.029 -0.029 -0.010
##     23     24     25     26     27     28     29     30     31     32     33
## 0.093  0.060 -0.056  0.120  0.007 -0.053  0.128 -0.050 -0.031  0.016  0.033
##     34     35     36
## 0.074  0.062 -0.075
```

En este caso, es solamente conveniente tomar $k = 1$ retraso para poder predecir mi futuro, ya que vemos que $\varphi_1 = \text{corr}(Y_t, Y_{t-1}) = 0.608$, donde los demás valores ya están muy alejados de este valor, teniendo en cuenta que este tipo de auto-correlación no toma en cuenta los efectos intermedios que hay entre el intervalo $(t, t - k)$

2.5. Técnicas de suavizado

2.5.1. Suavizado de la media móvil centrado

El método clásico de descomposición de series de tiempo se originó en la década de 1920 y fue ampliamente utilizado hasta la década de 1950. Todavía constituye la base de muchos métodos de descomposición de series temporales, por lo que es importante entender como funcionan. El primer paso en una descomposición clásica es usar un método de promedio móvil para estimar el ciclo de tendencia, por lo que comenzaremos analizando los promedios móviles.

Una media móvil de orden m se puede escribir como:

$$\hat{T}_t = \frac{1}{m} \sum_{j=-k}^k y_{t+j}$$

donde $m = 2k + 1$. Es decir, la estimación de la tendencia-ciclo en el momento t se obtiene promediando los valores de la serie temporal dentro de k periodos de t . También es probable que las observaciones que están cercanas en el tiempo tengan un valor cercano. Por lo tanto, el promedio elimina parte de la aleatoriedad en los datos, dejando un componente suave de ciclo-tendencia. A esto le llamamos **m -MA**, lo que significa un promedio móvil de orden m .

El orden de la media móvil determina la suavidad de la estimación del ciclo de tendencia. En general, un pedido más grande significa una curva más suave.

##		MAÍZ	5-MA
##	ene. 2014	1037733.6	NA
##	feb. 2014	841936.6	NA
##	mar. 2014	968867.5	991358.8
##	abr. 2014	1061894.8	1027990.1
##	may. 2014	1046361.4	1081497.0
##	jun. 2014	1220890.4	1128519.4
##	jul. 2014	1109470.9	1148031.9
##	ago. 2014	1203979.7	1120058.1
##	sep. 2014	1159457.2	1064673.7
##	oct. 2014	906492.2	1045880.5
##	nov. 2014	943968.5	988349.4
##	dic. 2014	1015504.7	917157.0
##	ene. 2015	916324.4	946967.9
##	feb. 2015	803495.1	1001471.9
##	mar. 2015	1055547.1	1094618.4
##	abr. 2015	1216488.3	1253043.0
##	may. 2015	1481237.2	1371282.1
##	jun. 2015	1708447.4	1441704.3
##	jul. 2015	1394690.7	1460744.0
##	ago. 2015	1407658.0	1371180.0
##	sep. 2015	1311686.6	1254655.2
##	oct. 2015	1033417.1	1228641.0
##	nov. 2015	1125823.7	1177462.4
##	dic. 2015	1264619.4	1153569.7
##	ene. 2016	1151765.0	1200708.3
##	feb. 2016	1192223.4	1234936.1
##	mar. 2016	1269109.9	1286436.8
##	abr. 2016	1296962.5	1371895.5
##	may. 2016	1522123.0	1425111.4
##	jun. 2016	1579058.8	1464868.6
##	jul. 2016	1458302.9	1478204.4
##	ago. 2016	1467896.1	1386857.5

```

## sep. 2016 1363641.1 1325648.5
## oct. 2016 1065388.9 1250034.3
## nov. 2016 1273013.8 1175338.9
## dic. 2016 1080231.7 1093163.7
## ene. 2017 1094419.1 1095613.0
## feb. 2017 952764.9 1079166.4
## mar. 2017 1077635.7 1145247.6
## abr. 2017 1190780.7 1281834.3
## may. 2017 1410637.8 1370827.5
## jun. 2017 1777352.4 1432177.4
## jul. 2017 1397730.8 1512794.4
## ago. 2017 1384385.5 1491355.6
## sep. 2017 1593865.6 1428406.3
## oct. 2017 1303444.0 1410410.4
## nov. 2017 1462605.5 1373013.4
## dic. 2017 1307751.5 1242178.5
## ene. 2018 1197400.4 1180518.8
## feb. 2018 939691.1 1160198.8
## mar. 2018 995145.6 1227687.5
## abr. 2018 1361005.3 1299975.7
## may. 2018 1645195.0 1430036.5
## jun. 2018 1558841.7 1509987.3
## jul. 2018 1589994.9 1522337.7
## ago. 2018 1394899.8 1501365.3
## sep. 2018 1422756.9 1515080.1
## oct. 2018 1540333.0 1479473.2
## nov. 2018 1627415.7 1460165.5
## dic. 2018 1411960.7 1418276.7
## ene. 2019 1298361.2 1350794.1
## feb. 2019 1213312.8 1271318.4
## mar. 2019 1202920.1 1279615.8
## abr. 2019 1230037.4 1324071.7
## may. 2019 1453447.6 1408249.8
## jun. 2019 1520640.7 1467289.7
## jul. 2019 1634203.5 1491537.2
## ago. 2019 1498119.5 1391296.4
## sep. 2019 1351274.6 1394914.8
## oct. 2019 952244.0 1321065.7
## nov. 2019 1538732.2 1238738.6
## dic. 2019 1264958.0 1194598.7
## ene. 2020 1086484.4 1277191.1
## feb. 2020 1130574.9 1211651.7
## mar. 2020 1365206.0 1272243.4
## abr. 2020 1211035.2 1360836.9
## may. 2020 1567916.6 1437117.4
## jun. 2020 1529451.7 1450338.2
## jul. 2020 1511977.6 1453254.9
## ago. 2020 1431310.0 1355666.1
## sep. 2020 1225618.7 1320221.6
## oct. 2020 1079972.6 1277761.8
## nov. 2020 1352228.9 1227006.4
## dic. 2020 1299678.9 1190681.9
## ene. 2021 1177533.1 1268104.1
## feb. 2021 1043996.2 1262005.5

```

```
## mar. 2021 1467083.3 1314802.2
## abr. 2021 1321736.0 1425085.9
## may. 2021 1563662.3 1503419.6
## jun. 2021 1728951.7 1525095.6
## jul. 2021 1435664.5 1527941.9
## ago. 2021 1575463.4 1483947.1
## sep. 2021 1335967.8 1446229.0
## oct. 2021 1343687.9 1449916.9
## nov. 2021 1540361.6 1417017.7
## dic. 2021 1454103.5 1373506.0
## ene. 2022 1410967.6 NA
## feb. 2022 1118409.3 NA
```

En la última columna de esta tabla, se muestra una media móvil de orden $m = 5$, que proporciona una estimación de la tendencia-ciclo.

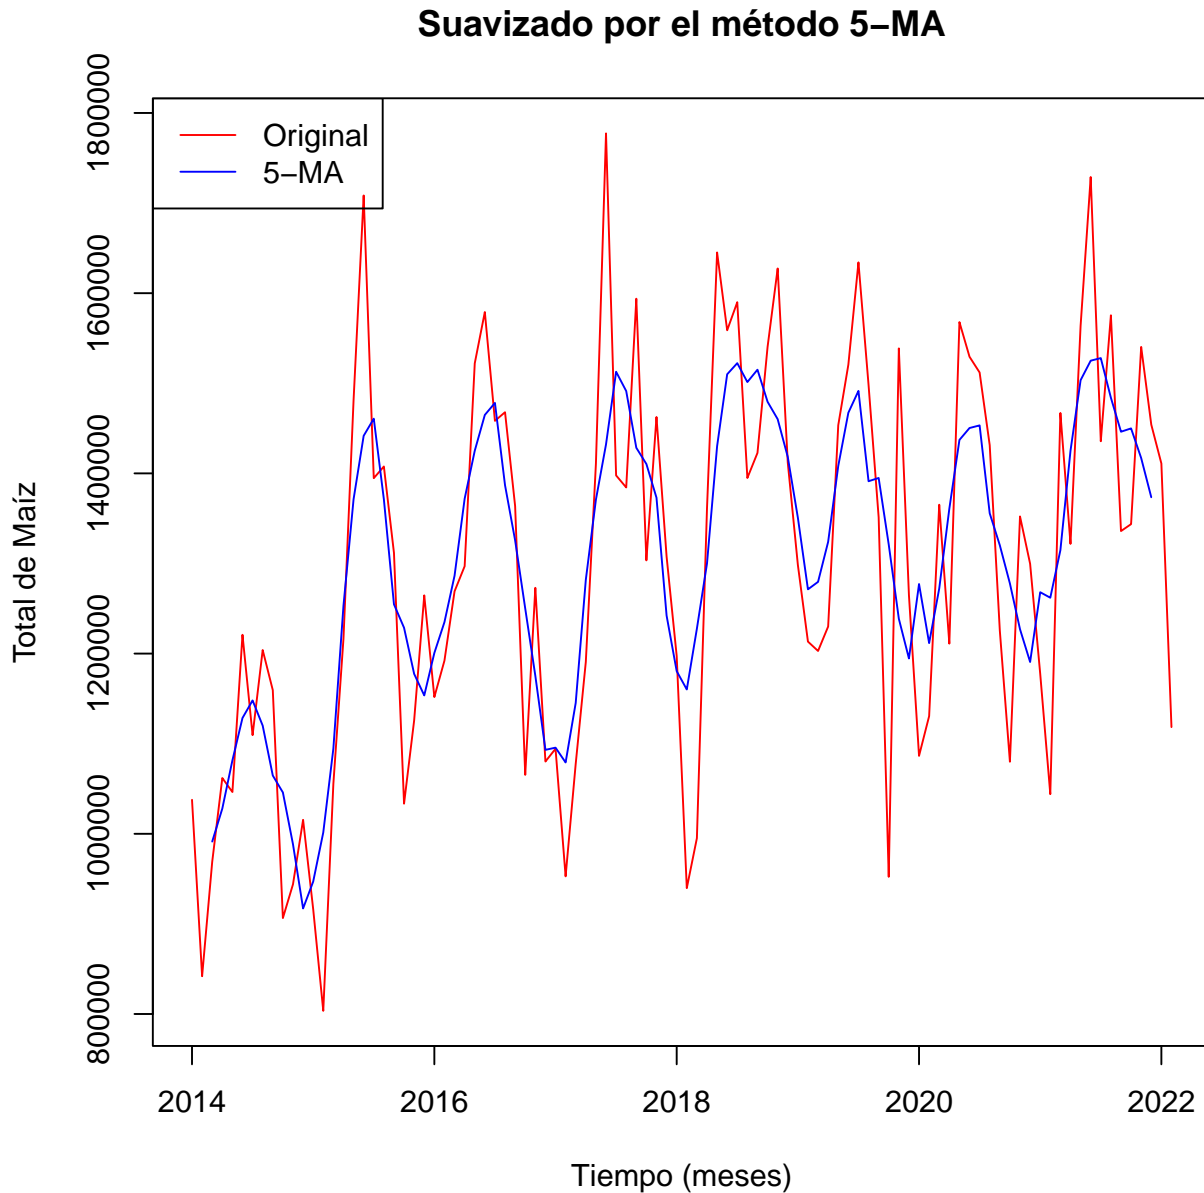
- El primer valor de esta columna es el promedio de las primero 5 observaciones, *ene.2014* – *mayo.2014*, es decir:

$$\frac{y_1 + y_2 + \cdots + y_5}{5}$$

- El segundo valor en la columna **5-MA** es el promedio de los valores para *feb.2014* – *jun.2014* y así sucesivamente.

Cada valor en la columna **5-MA** es el promedio de las observaciones en la ventana de 5 meses centrada en el mes correspondiente.

La columna **5-MA** contiene los valores de \hat{T}_t con $m = 2k + 1 = 5$ y $k = 2$. No hay valores ni para los primeros dos años ni para los dos últimos años, porque no tenemos observaciones en cada lado.



2.5.2. Suavizado de la media móvil hacia atrás


El método de **Promedio Móvil Simple** utiliza información histórica del desempeño de la variable que se desea pronosticar para poder generar un pronóstico de la misma a futuro. Es decir, se considera válida la premisa que el *pasado* es de utilidad para predecir el *futuro*. Su notación matemática es de la siguiente forma:

$$SMA = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

donde x_i son los valores de la variable, por tanto SMA es un promedio aritmético de k períodos atrás.

Dado que en la auto-correlación simple como en la parcial φ_1 dio casi cercano a 1, entonces para aplicar el método de medias móviles hacemos $k = 1$. Es decir: $Y_t = \frac{X_t + X_{t-1}}{2}$ para $t > 1$

Suavizado por el método SMA con k=1 retraso



Tenemos que $X_1 = 1037733.6$ (Valor de toneladas netas en Enero/2014) y $X_2 = 841936.6$ (Valor de toneladas netas en Febrero/2014), entonces dado lo anterior, tendremos que: $Y_2 = \frac{X_2 + X_1}{2}$, es decir, El valor predictor para Febrero/2014 (Y_2) es 939,835.1

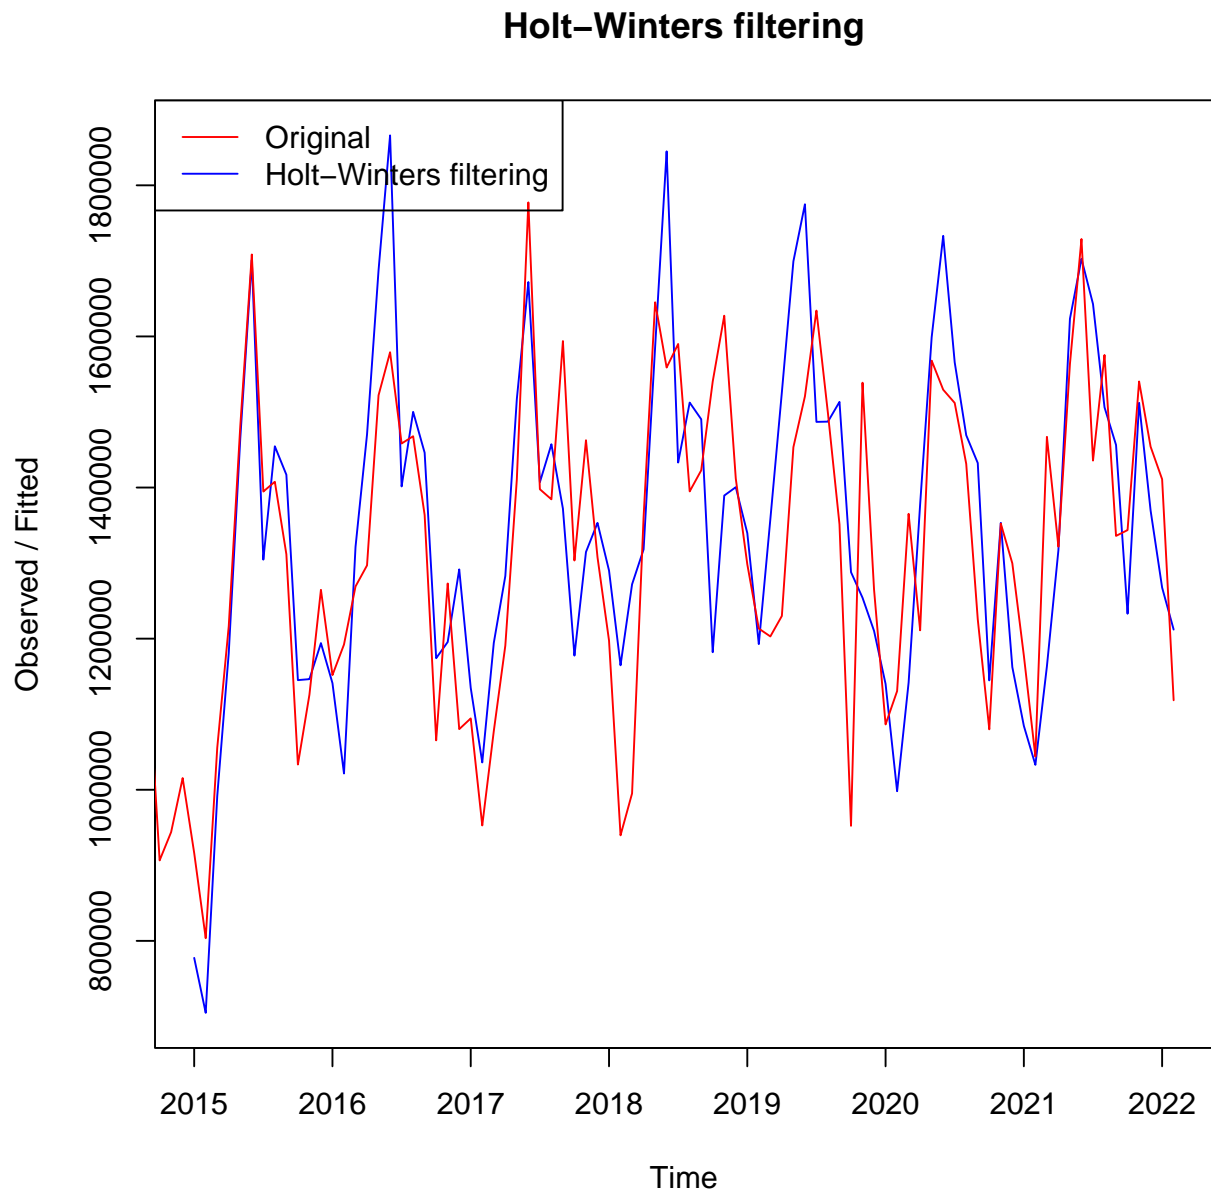
2.5.3. Suavizado por Método de Holt-Winters

En este método se toma en cuenta que contribuyen, como la **tendencia** y la **estacionalidad**, es decir, este método lleva a cabo un suavizado exponencial en la presencia de tendencias y estacionalidad. Utilizando el **packages forecast** para llevar a cabo este método.

```
## Holt-Winters exponential smoothing with trend and additive seasonal component.
##
## Call:
## HoltWinters(x = Maiz_ts)
##
## Smoothing parameters:
## alpha: 0.2890066
## beta : 0.02799386
```

```
## gamma: 0.374021
##
## Coefficients:
##          [,1]
## a    1517860.955
## b      5992.591
## s1   -131543.289
## s2   -151243.472
## s3    130452.879
## s4    244259.239
## s5    108864.905
## s6    101431.949
## s7    -23646.523
## s8   -154553.453
## s9     65965.856
## s10   -74598.762
## s11  -190997.612
## s12 -357811.540
```

Con lo anterior, tenemos que la gráfica a través de este método nos queda de la siguiente manera:



2.5.4. Suavizado por la función ETS() de R

El suavizado en R hace este procedimiento de una manera más sencilla con la función `ets()` de la paquetería TTR. El código nos quedaría de la siguiente manera:

```
Suavizado_Maiz_R <- ets(Maiz_ts, model = "ZZZ") #Suavizado por la función ets() en forma automática
```

Cuando se pone **model="ZZZ"** le indicamos a *R* que nos calcule cual es el método más conveniente. En `model = "Errores, Tendencia, Estacionalidad"`, los cuales podremos utilizar parámetros de la siguiente manera:

- N = No hacer caso.
- A = Tipo aditiva.
- M = Tipo Multiplicativa.
- Z = Que R calcule el tipo que se va a requerir.

Coefficientes del suavizado

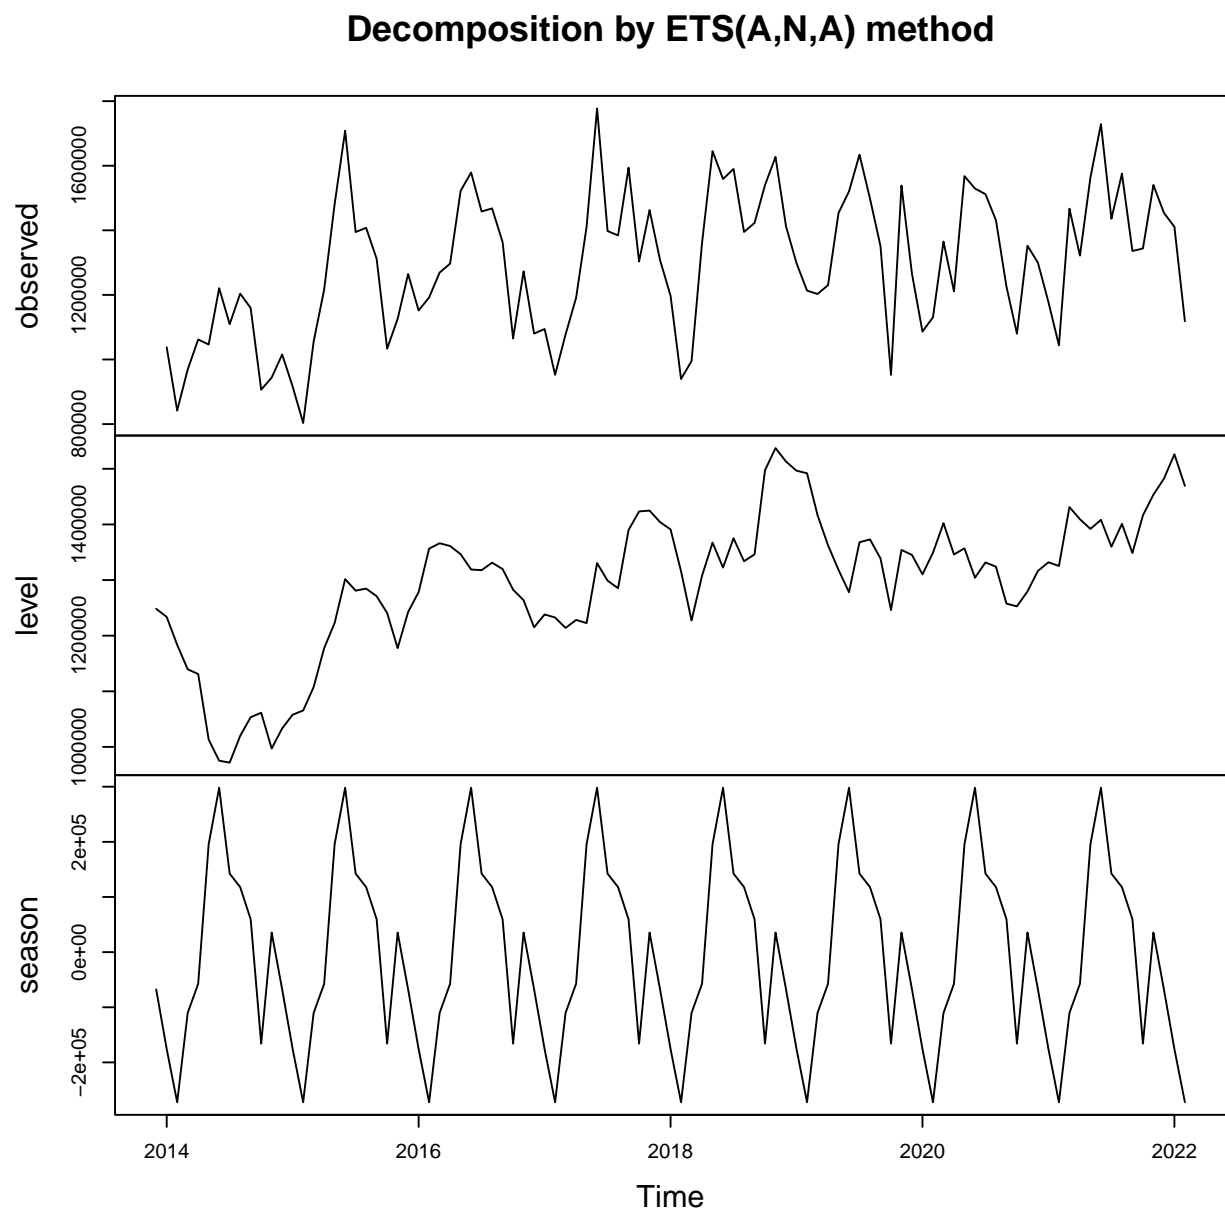
```
## ETS(A,N,A)
##
## Call:
## ets(y = Maiz_ts, model = "ZZZ")
##
## Smoothing parameters:
##   alpha = 0.4203
##   gamma = 1e-04
##
## Initial states:
##   l = 1248315.1426
##   s = -67603.11 35512 -165933.2 59579.95 117925.9 142350.2
##        298054.5 195854.2 -57446.23 -110278.5 -272243.4 -175772.1
##
## sigma: 127565.4
##
##      AIC      AICc      BIC
## 2768.471 2774.325 2807.246
```

Lo anterior, tenemos que R nos da un modelo de la forma:

- Error de tipo aditivo.
- Tendencia no hacer caso.
- Estacionalidad de tipo aditivo


Descomposición de la serie por el método ETS()

La descomposición del modelo anterior queda de la siguiente manera:



Gráfica del suavizado ETS() vs original

Haciendo una gráfica de la serie maíz con el suavizado exponencial por R , tendremos lo siguiente:



2.6. Pruebas de Estacionariedad

Recordando...

P-valor

Con base en los datos proporcionados es que se puede realizar la prueba, y así determinar si se puede rechazar o no la hipótesis nula; la forma de determinar esto es con base en los diferentes estadísticos, o bien, usando el p-valor de la prueba. La forma más sencilla de saber que es el p-valor, es verlo como la probabilidad de rechazar la hipótesis nula cuando esta sea verdadera. Por lo tanto:

- Si $p\text{-valor} < \alpha$, entonces se puede rechazar la hipótesis nula (Se acepta H_a).
- Si $p\text{-valor} > \alpha$, hay evidencia para que **NO** se rechace la hipótesis nula (Se acepta H_0).

Prueba de Dickey-Fuller Aumentada para raíz unitaria

$H_0 = \text{No estacionaria (Raíz Unitaria)}.$

$H_a = \text{Es estacionaria}.$

Prueba de Phillips-Perron

Es una modificación de la prueba de Dickey-Fuller. Esta prueba corrige la auto-correlación y heterocedasticidad (Varianza NO constante) en los errores para comprobar la existencia de la serie.

$H_0 = \text{No estacionaria (Raíz Unitaria)}.$

$H_a = \text{Es estacionaria}.$

Una manera de corregir la NO estacionariedad es utilizando diferencias

Prueba Ljung Box

$H_0 = \text{Ruido Blanco}.$

$H_a = \text{NO hay Ruido Blanco}.$

Ruido Blanco

El ruido blanco cumple las siguientes características:

$E[\varepsilon_t] = 0, \text{ es decir, media igual a } 0.$

$Var[\varepsilon_t] = c, \text{ es decir, varianza constante}.$

$Cov(\varepsilon_t, \varepsilon_{t-k}) = 0, \text{ es decir, no hay correlación}$

Siguiendo la **metodología de Box-Jenkins**, lo primero sería realizar las pruebas de estacionariedad (*Prueba de Dickey-Fuller aumentada* y *Phillips-Perron*) para comprobar que la serie sea o no estacionaria.

2.6.1. Prueba de Dickey-Fuller aumentada

Para realizar la prueba de Dickey-Fuller aumentada sobre la serie que estamos ocupando (MAÍZ), utilizamos el siguiente código:

```
## Warning in adf.test(Maiz_ts, alternative = "stationary", k = 0): p-value smaller than
## printed p-value
##
## Augmented Dickey-Fuller Test
##
## data:  Maiz_ts
## Dickey-Fuller = -5.1793, Lag order = 0, p-value = 0.01
## alternative hypothesis: stationary
```

Con un valor del p-valor del 0.01, menor al $\alpha = 0.05$ nivel de significancia de la prueba, se acepta la hipótesis alternativa (H_a) y **rechazamos la hipótesis nula** (H_0), lo que contrasta que la serie presenta un **comportamiento Estacionario** ($p\text{-valor} < \alpha$).

Para comparar los resultados de la prueba de Dickey-Fuller aumentada utilizaremos la *Prueba Phillips-Perron* y comprobaremos si esta igual señala la existencia de un comportamiento ESTACIONARIO.

2.6.2. Prueba de Phillips-Perron

```
## Warning in pp.test(Maiz_ts, alternative = "stationary"): p-value smaller than printed
p-value

##
## Phillips-Perron Unit Root Test
##
## data: Maiz_ts
## Dickey-Fuller Z(alpha) = -46.443, Truncation lag parameter = 3, p-value
## = 0.01
## alternative hypothesis: stationary
```

Con un p-valor menor al 0.05 nivel de significancia, al igual que la *prueba Dickey-Fuller Aumentada*, la prueba de Phillips-Perron contrasta que la serie es una **serie estacionaria**.

Conclusión

Dada estas dos pruebas, tenemos como conclusión que $d = 0$, entonces tendremos que encontrar un proceso de la forma $ARMA(p, q) = ARIMA(p, 0, q)$

2.7. ARIMA(p, d, q)

Dada la prueba de estacionariedad, podemos confirmar que la serie *Maiz_ts* se puede considerar como un **proceso estacionario**, y que, a su vez este se puede modelar a partir de un proceso $AR(p)$ y $MA(q)$; es decir, un **proceso $ARMA(p, q)$ estacionario**.

Dentro de la metodología estándar de estimación de modelos ARMA, el proceso se puede realizar a partir de candidatos posibles que puedan modelar adecuadamente el *comportamiento estocástico de la serie*. Por lo cual propongo 5 candidatos a modelos $ARIMA(p, d, q)$, los cuales son:

- $ARIMA(1, 0, 1)$
- $ARIMA(1, 0, 0)$
- $ARIMA(2, 0, 1)$
- $ARIMA(1, 0, 2)$
- $ARIMA(0, 0, 1)$

El objetivo de esto será comparar y ver cual de estos candidatos tiene el menor **criterio de información**.

El código que ocuparemos para estimar los procesos ARIMA seleccionados sobre la serie es el siguiente:

```
ModA_ARIMA =arima(Maiz_ts , order = c(1,0,1))
ModB_ARIMA =arima(Maiz_ts , order = c(1,0,0))
ModC_ARIMA =arima(Maiz_ts , order = c(2,0,1))
ModD_ARIMA =arima(Maiz_ts , order = c(1,0,2))
ModE_ARIMA =arima(Maiz_ts , order = c(0,0,1))
```

2.7.1. Criterios de Información.

El *Criterio de Información de Akaike (AIC)* son medidas de la calidad relativa de un modelo que representan el ajuste y el número de términos en el modelo. Este criterio se utiliza para comparar diferentes modelos. Sin embargo, el modelo con el valor más pequeño para un conjunto de predictores **NO necesariamente ajusta los datos adecuadamente**. Utilice también pruebas y gráficas de residuos para evaluar que tan bien se ajusta el modelo a los datos.

El código que ocuparemos para comparar los *criterios de información* de los modelos propuestos es:

```
ModA_ARIMA$aic
## [1] 2650.104

ModB_ARIMA$aic
## [1] 2648.111

ModC_ARIMA$aic
## [1] 2651.426

ModD_ARIMA$aic
## [1] 2651.483

ModE_ARIMA$aic
## [1] 2660.408
```

Podemos observar que al hacer la comparación de modelos utilizando el **Criterio de Información de Akaike**, el modelo que cuenta con el menor valor es el modelo $ARIMA(1, 0, 0)$, por lo cual ese es el modelo que ocuparemos para realizar las pruebas sobre los supuestos y, en el caso de que los supuestos se cumplan, el modelo que podremos ocupar para realizar el pronóstico de la serie. Podemos ocupar la función `summary()` sobre el modelo seleccionado para observar las estimaciones de los parámetros del modelo:

```
##
## Call:
## arima(x = Maiz_ts, order = c(1, 0, 0))
##
## Coefficients:
##          ar1    intercept
##          0.6152 1289609.65
## s.e.    0.0796   44640.69
##
## sigma^2 estimated as 2.979e+10:  log likelihood = -1321.06,  aic = 2648.11
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 2136.598 172610.3 139227.9 -1.721672 11.07217 0.8852303 0.00743361
```

Con lo anterior, calculamos los parámetros a través de *mínimos cuadrados*. Con la ayuda de R obtuvimos la estimación de esos parámetros así que tenemos que el modelo matemáticamente de $ARIMA(1, 0, 0) = AR(1)$ esta dado de la siguiente manera:

$$Y_t = \Phi_0 + \Phi_1 Y_{t-1} + \varepsilon_t$$

$$Y_t = 1289609.65 + 0.6152 Y_{t-1} + \varepsilon_t$$


2.8. SARIMA(p,d,q)(P,D,Q)[m]

Una manera de poder obtener de forma automática un modelo adecuado es usando la función `auto.arima()`, con lo cual obtenemos lo siguiente:


```
## Series: Maiz_ts
## ARIMA(1,0,1)(0,1,1)[12] with drift
##
## Coefficients:
##          ar1          ma1          sma1          drift
##          0.7384    -0.3824    -0.7926    3268.075
## s.e.    0.1457     0.1997     0.2065    1071.698
##
## sigma^2 = 1.704e+10: log likelihood = -1138.93
## AIC=2287.86   AICc=2288.61   BIC=2300.13
```

2.8.1. Correlograma ACF y PACF del modelo ARIMA(1,0,0)

Correlograma simple del modelo ARIMA(1,0,0)



Correlograma parcial del modelo ARIMA(1,0,0)



Tanto en el Correlograma Simple, como el en Correlograma Parcial existen valores significativo φ . Este

tipo de comportamiento en los correlogramas indican que aún hay factores que no están considerando en los modelos y afectan de manera importante el comportamiento de la serie temporal.

Es importante observar que, de acuerdo con el correlograma simple, los valores fuera del intervalo representan un comportamiento similar, ya que se repiten cada determinado tiempo de acuerdo al rezago de la serie, en este caso, cada múltiplo del rezago 12. **Este tipo de comportamiento es bastante común en las series temporales que presentan un comportamiento estacional;** es decir, que tiene un efecto temporal que se repite cada determinado período.

Para poder estimar modelos que consideren el comportamiento estacional de las series podemos ocupar los modelos *SARIMA*. Para incorporar el comportamiento estacional de la serie, podemos anexar un factor de diferenciación adicional al de integración, con el fin de diferencial de acuerdo con el componente estacional. Para empezar a estimar modelos *SARIMA*, propongo realizar 1 diferencia estacional que se le deberá aplicar a la serie (lo que significa que debemos de diferenciar sobre 12 unidades, ya que la serie es una serie mensual).

De acuerdo a lo anterior, propongo 9 propuestas de modelos SARIMA en donde únicamente variaremos el número de valores Autorregresivos y Medias Móviles, así como el orden de integración normal del modelo.

```
ndiffs(Maiz_ts) # Nos da el número de diferenciación ordinaria
## [1] 1

nsdiffs(Maiz_ts) #Nos da el número de diferenciación estacional
## [1] 1
```

Modelos SARIMA(p,d,q)(P,D,Q) propuestos

```
SARIMA_1<- arima(Maiz_ts,order=c(1,1,1), seasonal = list(order=c(0,1,1)))
SARIMA_2<- arima(Maiz_ts,order=c(0,1,1), seasonal = list(order=c(0,1,1)))
SARIMA_3<- arima(Maiz_ts,order=c(1,1,0), seasonal = list(order=c(0,1,1)))
SARIMA_4<- arima(Maiz_ts,order=c(1,1,1), seasonal = list(order=c(1,1,1)))
SARIMA_5<- arima(Maiz_ts,order=c(0,1,1), seasonal = list(order=c(1,1,1)))
SARIMA_6<- arima(Maiz_ts,order=c(1,1,0), seasonal = list(order=c(1,1,1)))
SARIMA_7<- arima(Maiz_ts,order=c(1,1,1), seasonal = list(order=c(1,1,0)))
SARIMA_8<- arima(Maiz_ts,order=c(0,1,1), seasonal = list(order=c(1,1,0)))
SARIMA_9<- arima(Maiz_ts,order=c(1,1,0), seasonal = list(order=c(1,1,0)))
```

Vamos a utilizar el mejor modelo de acuerdo con los **Criterios de Información**.

2.8.2. Criterios de Información

```
SARIMA_1$aic
## [1] 2265.639

SARIMA_2$aic
## [1] 2266.262


SARIMA_3$aic
## [1] 2274.933

SARIMA_4$aic
```


```
## [1] 2265.459  
  
SARIMA_5$aic  
  
## [1] 2265.818  
  
SARIMA_6$aic  
  
## [1] 2274.692  
  
SARIMA_7$aic  
  
## [1] 2275.807  
  
SARIMA_8$aic  
  
## [1] 2277.278  
  
SARIMA_9$aic  
  
## [1] 2285.34
```

Conclusión: De acuerdo a los resultados de cada modelo, el mejor modelo obtenido es el modelo $SARIMA(1, 1, 1)(1, 1, 1)[12]$.

Correlograma simple del modelo SARIMA(1,1,1)(1,1,1)[12]

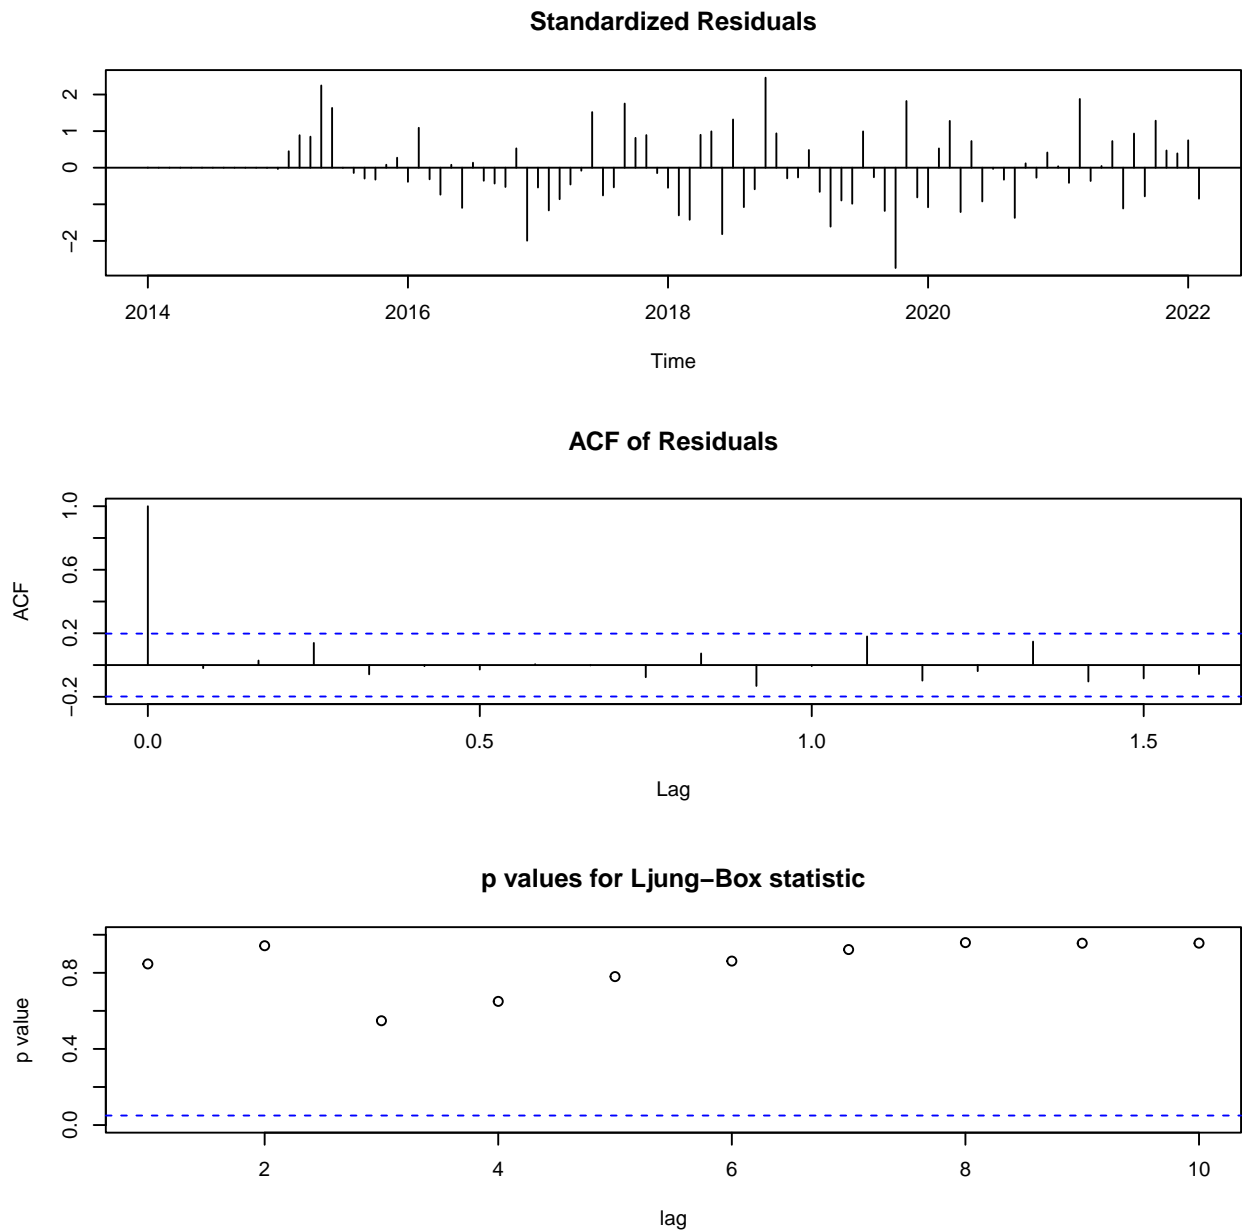


Correlograma parcial del modelo ARIMA(1,1,1)(1,1,1)[12]



En esta ocasión observamos que en el Correlograma Simple, como el en Correlograma Parcial solamente hay un valor φ significativo, pero es muy muy mínimo. Así que en esta ocasión nuestro modelo se ajusta muy bien.

2.8.3. Diagnostico del modelo SARIMA(1,1,1)(1,1,1)[12]




En la gráfica podemos ver los p-valor de **Ljung Box**, en donde recordemos que si el $P\text{-valor} > 0,05$, entonces hay **Ruido Blanco**.

Dado lo anterior, vemos que el modelo dado tiene *Ruido Blanco*, con esto concluimos que se ajusta bien. También podemos notar que la gráfica de *ACF* no hay valores de significancia (afuera de la franja azul), esto quiere decir que no hay correlación en los errores, es decir:


$$\text{corr}(\varepsilon_t, \varepsilon_{t-k}) = 0$$

Para todo $k \geq 1$ que pertenezca a los no. Naturales.

2.8.4. Gráfico de Raíces Unitarias



Las raíces del proceso $SARIMA(1,1,1)(1,1,1)$ en el modelo propuesto se encuentran dentro del *círculo unitario* en el caso de *AR*, pero en las del modelo *MA* están justo en la raya del círculo. Una vez comprobado este supuesto, podremos continuar con realizar los supuestos sobre los errores de las estimaciones del modelo. El cumplimiento de los supuestos básicos sobre los residuos es de suma importancia para el uso de pronósticos con modelos de series de tiempo, debido a que lo que se busca es que no exista (o que al menos no de manera importante) ninguna variable determinista que pueda afectar al modelo, dejando "limpia" esa variable, y por lo tanto, lo que sobre sea una variable **puramente aleatoria**. Para esto, tendremos que contrastar con unas últimas pruebas si estos errores se distribuyen o no de manera **normal**. Como una primera impresión, podemos ocupar la función `checkresiduals()`.



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,1,1)(1,1,1)[12]
## Q* = 16.244, df = 16, p-value = 0.436
##
## Model df: 4.    Total lags used: 20
```

Al utilizar la función, podemos apreciar una imagen que cuenta con 3 gráficas útiles:

1. . Gráfica de los residuos: Podemos contrastar que, en efecto, los errores se mantienen en una media constate igual a cero, y dentro de unos intervalos de varianza entre 250000 y 250000.
2. Histograma junto con una gráfica de distribución: Observamos que la serie tiene un comportamiento ligeramente normal, ya que no presenta un importante sesgo ni una fuerte curtosis.

Para contrastar el cumplimiento del supuesto de **NO autocorrelación**, realizamos la prueba **Ljung-Box** sobre los errores.

Prueba Ljung-Box

H_0 : *Ruido Blanco*.

H_a : *No hay Ruido Blanco*.

```
##
## Box-Ljung test
##
## data: SARIMA_4$residuals
## X-squared = 0.037373, df = 1, p-value = 0.8467
```

Al realizar la prueba Ljung-Box sobre los residuos del modelo, con un p-valor mucho mayor al 0.05 nivel de significancia, podemos **aceptar la hipótesis nula** H_0 de que la serie no tiene problemas de auto-correlación.

2.8.5. Pruebas de Normalidad

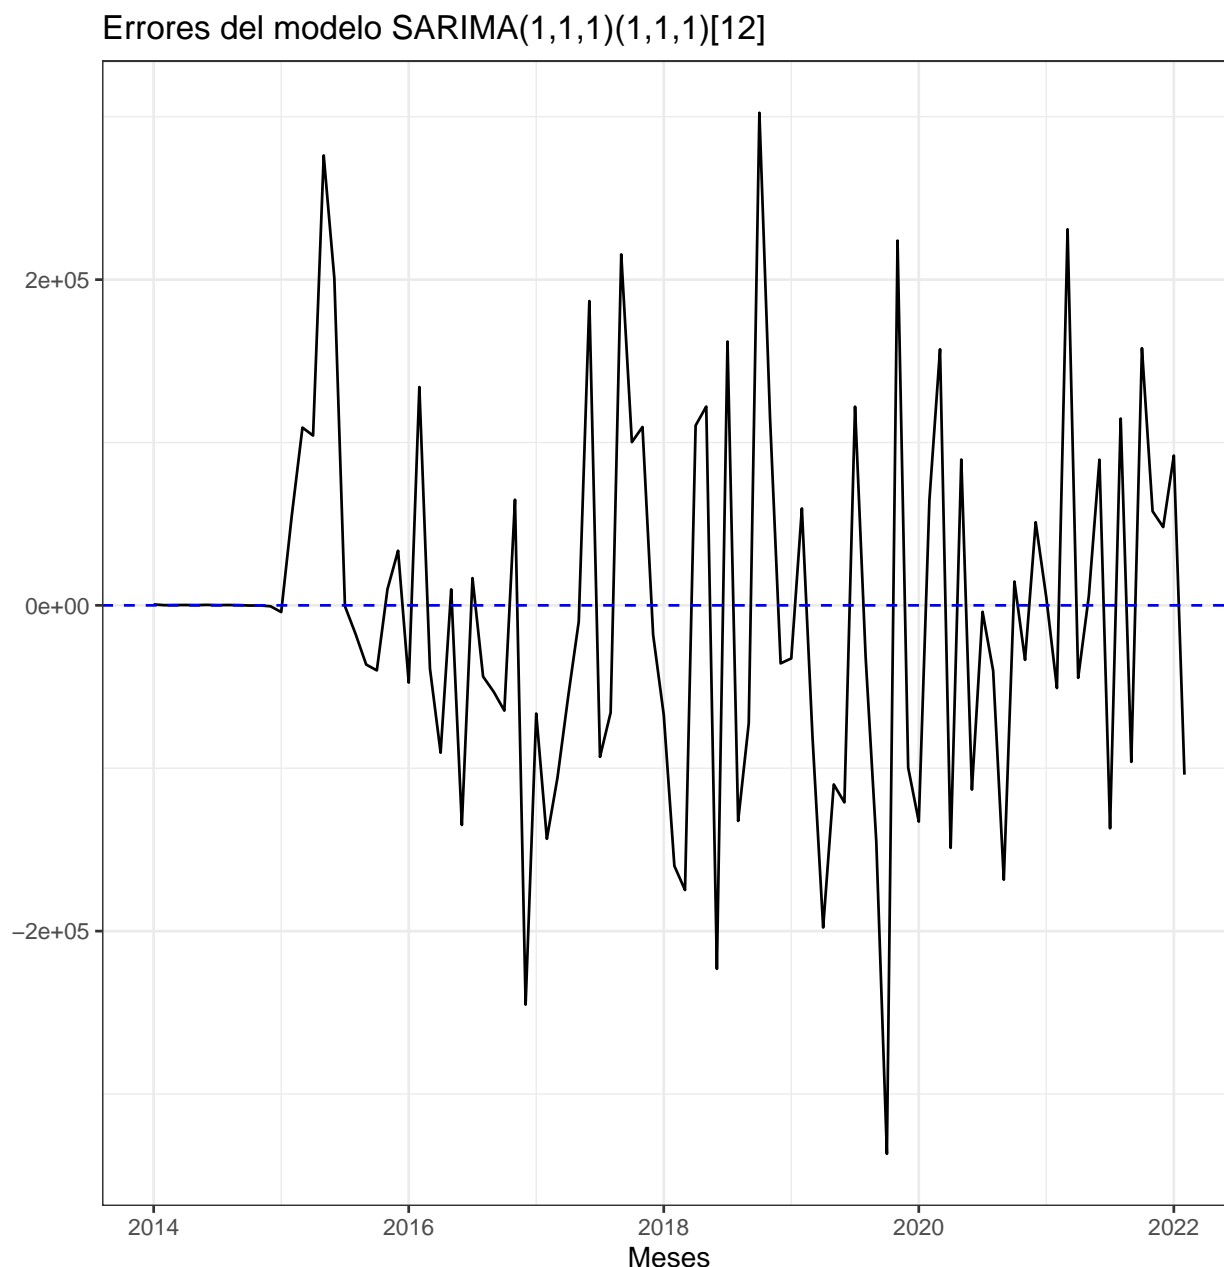
Para realizar la prueba de normalidad, vamos a proponer dos pruebas estadísticas:

1. Prueba de Jarque-Bera.
2. Prueba de Shapiro.

Las pruebas están dadas de la siguiente manera:

- H_0 : Los datos se comportan como una distribución normal.
- H_a : Los datos NO se comportan como una distribución normal.

El uso de las pruebas, al igual que el uso de las pruebas de raíces unitarias, servirán para confirmar de mejor manera el cumplimiento o el incumplimiento del supuesto de normalidad de la serie. Lo anterior lo hacemos de la siguiente manera:



Prueba de Jarque-Bera

En estadística, la **prueba de Jarque-Bera** es una prueba de bondad de ajuste para comprobar si una muestra de datos tienen la asimetría y la curtosis de una distribución normal

```
##
##  Jarque Bera Test
##
## data:  SARIMA_4$residuals
## X-squared = 0.94851, df = 2, p-value = 0.6223
```

El resultado de la prueba, al igual que otros contrastes que hemos mencionado, se puede confirmar observando el p – *valor* obtenido. De acuerdo con los resultados de la prueba, con un p -valor mayor al 0.05, **Se Acepta la hipótesis nula de normalidad (H_0)** sobre los residuos del modelo seleccionado. Confirmamos que **el modelo tiene residuos que se distribuyen de manera normal**. Por otra parte, procedemos a confirmar el supuesto de normalidad sobre los residuos utilizando de manera paralela la **prueba de Shapiro**.


Prueba de Shapiro-Wilk

La Prueba de Shapiro-Wilk se usa para contrastar la normalidad de un conjunto de datos.

```
##
## Shapiro-Wilk normality test
##
## data: SARIMA_4$residuals
## W = 0.98651, p-value = 0.4201
```

El p-valor de la prueba, con un valor de 0.4401, mucho mayor al nivel de significancia del 0.05, **se acepta la hipótesis nula** (H_0) de normalidad sobre los residuos del modelo $SARIMA(1, 1, 1)(1, 1, 1)[12]$.

2.8.6. Contraste de normalidad con Q-Q plot



Prueba de Dickey-Fuller Aumentada a residuos de $SARIMA(1,1,1)(1,1,1)[12]$

```
##
## Augmented Dickey-Fuller Test
##
## data: SARIMA_4$residuals
## Dickey-Fuller = -3.9979, Lag order = 4, p-value = 0.01234
## alternative hypothesis: stationary
```

Podemos observar que la gran mayoría de puntos se alinean dentro de los datos simulados normales, de tal manera que se confirma que los residuos de la serie presentan una distribución normal, con una media igual a cero $E[\varepsilon] = 0$ y una varianza constante $Var[\varepsilon] = c$. Con estas pruebas podemos confirmar que los pronósticos que arroja el modelo serán los más eficientes posibles.


Conclusión: El modelo $AR(1, 1, 1)(1, 1, 1)[12]$ es eficiente para poder hacer un pronóstico.

2.9. Pronósticos

2.9.1. Predicción usando la función ETS() de R


##		Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	Mar 2022	1358901	1195419.1	1522382	1108877.1	1608924
##	Apr 2022	1411741	1234408.2	1589074	1140533.8	1682948
##	May 2022	1665017	1474839.0	1855195	1374164.8	1955869
##	Jun 2022	1767237	1565028.4	1969446	1457985.6	2076489
##	Jul 2022	1611548	1397985.5	1825111	1284932.1	1938165
##	Aug 2022	1587120	1362777.2	1811463	1244017.1	1930224
##	Sep 2022	1528756	1294127.7	1763385	1169922.8	1887590
##	Oct 2022	1303272	1058790.7	1547754	929369.9	1677175
##	Nov 2022	1504711	1250758.0	1758664	1116323.5	1893098
##	Dec 2022	1401595	1138511.8	1664678	999243.9	1803946
##	Jan 2023	1293426	1021518.9	1565333	877580.0	1709272
##	Feb 2023	1196922	916464.1	1477379	767998.8	1625844
##	Mar 2023	1358901	1070149.6	1647652	917294.1	1800507
##	Apr 2023	1411741	1114928.2	1708554	957804.9	1865677
##	May 2023	1665017	1360355.5	1969678	1199077.5	2130957
##	Jun 2023	1767237	1454924.4	2079550	1289595.9	2244879
##	Jul 2023	1611548	1291767.1	1931330	1122485.2	2100612
##	Aug 2023	1587120	1260041.1	1914199	1086895.9	2087345
##	Sep 2023	1528756	1194538.5	1862974	1017614.3	2039898
##	Oct 2023	1303272	962065.3	1644479	781441.3	1825103
##	Nov 2023	1504711	1156654.8	1852767	972405.1	2037016
##	Dec 2023	1401595	1046822.2	1756368	859016.9	1944173
##	Jan 2024	1293426	932061.4	1654791	740766.5	1846086
##	Feb 2024	1196922	829080.2	1564763	634356.6	1759487
##	Mar 2024	1358901	984697.4	1733104	786606.1	1931195
##	Apr 2024	1411741	1031282.4	1792200	829879.7	1993602
##	May 2024	1665017	1278404.1	2051630	1073743.6	2256290
##	Jun 2024	1767237	1374566.6	2159908	1166699.3	2367775
##	Jul 2024	1611548	1212912.0	2010185	1001886.6	2221210
##	Aug 2024	1587120	1182606.1	1991634	968469.3	2205771
##	Sep 2024	1528756	1118448.5	1939064	901244.7	2156268
##	Oct 2024	1303272	887251.7	1719293	667023.7	1939521
##	Nov 2024	1504711	1083054.7	1926367	859843.4	2149578
##	Dec 2024	1401595	974377.6	1828812	748222.5	2054967
##	Jan 2025	1293426	860719.0	1726133	631657.8	1955194
##	Feb 2025	1196922	758791.2	1635052	526858.9	1866984

## Mar 2025	1358901	915415.6	1802386	680648.7	2037153
## Apr 2025	1411741	962965.2	1860517	725397.6	2098084
## May 2025	1665017	1211012.1	2119022	970676.4	2359358
## Jun 2025	1767237	1308062.8	2226412	1064990.5	2469484
## Jul 2025	1611548	1147261.9	2075835	901483.5	2321613
## Aug 2025	1587120	1117777.5	2056463	869322.5	2304918
## Sep 2025	1528756	1054411.1	2003101	803307.9	2254205
## Oct 2025	1303272	823976.9	1782568	570253.3	2036291
## Nov 2025	1504711	1020515.8	1988906	764198.4	2245223
## Dec 2025	1401595	912549.4	1890640	653664.3	2149526
## Jan 2026	1293426	799577.6	1787274	538150.0	2048702
## Feb 2026	1196922	698314.4	1695529	434367.6	1959476
## Mar 2026	1358901	855581.7	1862220	589140.8	2128661
## Apr 2026	1411741	903754.2	1919728	634842.1	2188640
## May 2026	1665017	1152404.7	2177629	881044.1	2448990
## Jun 2026	1767237	1250040.8	2284434	976253.6	2558221
## Jul 2026	1611548	1089808.2	2133289	813615.6	2409481
## Aug 2026	1587120	1060875.5	2113365	782298.4	2391942
## Sep 2026	1528756	998045.1	2059467	717103.6	2340409
## Oct 2026	1303272	768132.2	1838413	484846.1	2121699
## Nov 2026	1504711	965177.9	2044244	679566.4	2329855
## Dec 2026	1401595	857704.8	1945485	569786.7	2233403
## Jan 2027	1293426	745213.3	1841639	455007.0	2131845
## Feb 2027	1196922	644418.1	1749425	351940.4	2041903



2.9.2. Predicción usando Holt Winter


##	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep
## 2022			1392310	1378603	1666292	1786091	1656689	1655248	1536163
## 2023	1392782	1231961	1464221	1450514	1738203	1858002	1728600	1727160	1608074
## 2024	1464693	1303872	1536132	1522425	1810114	1929913	1800511	1799071	1679985
## 2025	1536604	1375783	1608044	1594336	1882025	2001824	1872422	1870982	1751896
## 2026	1608515	1447694	1679955	1666247	1953936	2073735	1944333	1942893	1823807
## 2027	1680426	1519605							
##	Oct	Nov	Dec						
## 2022	1411248	1637760	1503188						
## 2023	1483159	1709671	1575099						
## 2024	1555070	1781582	1647010						
## 2025	1626981	1853493	1718921						
## 2026	1698893	1925404	1790832						
## 2027									



2.9.3. Predicción usando Auto.Arima()

##	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Mar 2022	1423619	1237049.2	1642395	1149516.3	1773338
## Apr 2022	1347140	1159642.2	1569382	1072382.0	1703518
## May 2022	1610709	1374438.1	1893586	1265304.3	2065659
## Jun 2022	1727214	1467578.8	2039589	1348092.2	2230333
## Jul 2022	1607550	1365737.4	1898524	1254464.3	2076218
## Aug 2022	1627400	1381110.0	1924130	1267881.5	2105514
## Sep 2022	1413268	1202219.1	1666850	1104995.4	1821532
## Oct 2022	1224287	1044146.5	1440094	960977.0	1571431
## Nov 2022	1618009	1372159.4	1914449	1259203.1	2095773
## Dec 2022	1450403	1232626.6	1712356	1132386.4	1872281
## Jan 2023	1333857	1135417.0	1572109	1043949.6	1717355
## Feb 2023	1184494	1010597.9	1392728	930284.7	1519413
## Mar 2023	1493725	1247296.4	1796199	1135571.5	1983801

## Apr 2023	1372176	1144983.9	1651266	1042043.7	1824475
## May 2023	1692395	1403579.2	2049691	1273403.4	2272659
## Jun 2023	1755726	1453759.2	2129985	1317844.4	2363877
## Jul 2023	1654394	1371156.9	2005054	1243568.3	2224011
## Aug 2023	1644273	1362654.3	1992964	1235803.8	2210708
## Sep 2023	1415615	1177015.8	1709926	1069239.0	1893170
## Oct 2023	1249748	1041938.9	1505279	947849.8	1663988
## Nov 2023	1600349	1326778.5	1938920	1203511.2	2150269
## Dec 2023	1479456	1228723.7	1789132	1115574.9	1982136
## Jan 2024	1358424	1130365.3	1639476	1027278.8	1814339
## Feb 2024	1192241	994962.1	1434551	905566.0	1584918
## Mar 2024	1571503	1293666.6	1918173	1169237.5	2135963
## Apr 2024	1435830	1183128.4	1750784	1069861.5	1948477
## May 2024	1740677	1426823.7	2134220	1286779.9	2382412
## Jun 2024	1856671	1518981.6	2281041	1368550.9	2549140
## Jul 2024	1663751	1364528.8	2038705	1230949.8	2275055
## Aug 2024	1720707	1409946.2	2110533	1271325.5	2356461
## Sep 2024	1472273	1210848.8	1798815	1093863.9	2004134
## Oct 2024	1362601	1122678.7	1661662	1015148.5	1849395
## Nov 2024	1680545	1377686.2	2060254	1242535.3	2299698
## Dec 2024	1560807	1281799.3	1909898	1157101.8	2129681
## Jan 2025	1462968	1203306.0	1787274	1087100.7	1991170
## Feb 2025	1234952	1019826.9	1502400	923221.4	1669944
## Mar 2025	1603006	1290787.1	2002632	1153590.3	2258754
## Apr 2025	1484223	1194189.6	1855794	1066828.8	2094107
## May 2025	1795247	1434865.1	2260509	1277515.1	2560720
## Jun 2025	1914947	1526541.3	2417907	1357336.6	2743215
## Jul 2025	1747605	1396009.0	2201816	1242568.8	2495045
## Aug 2025	1786661	1425991.8	2253053	1268707.2	2554379
## Sep 2025	1536459	1231179.7	1929415	1097594.1	2182381
## Oct 2025	1379542	1108558.3	1727217	989692.5	1950461
## Nov 2025	1756073	1401897.3	2213947	1247414.4	2509709
## Dec 2025	1607299	1286204.5	2021258	1145861.9	2288072
## Jan 2026	1492011	1196337.6	1872316	1066883.5	2116994
## Feb 2026	1287149	1036139.0	1608542	925867.4	1814580
## Mar 2026	1657897	1306756.3	2118605	1155267.8	2419672
## Apr 2026	1527649	1204316.3	1951782	1064802.6	2228900
## May 2026	1864814	1459803.1	2400446	1286102.3	2752672
## Jun 2026	1968969	1537828.8	2540668	1353284.0	2917396
## Jul 2026	1814849	1420415.6	2336610	1251279.2	2679776
## Aug 2026	1837606	1437416.3	2367326	1265895.1	2715906
## Sep 2026	1578388	1240093.0	2023900	1094549.8	2315892
## Oct 2026	1410701	1111919.2	1802710	983019.2	2058881
## Nov 2026	1798056	1407124.4	2315248	1239504.9	2655440
## Dec 2026	1653114	1296903.6	2123018	1143845.5	2431408
## Jan 2027	1528563	1201943.0	1958288	1061322.2	2239719
## Feb 2027	1323357	1044937.9	1687896	924637.9	1925729



2.9.4. Predicción usando SARIMA(1,1,1)(1,1,1)[12]

```
SARIMA_4<- arima(Maiz_ts,order=c(1,1,1), seasonal = list(order=c(1,1,1)))
Pronostico_SARIMA <- forecast(SARIMA_4, h=60)
Pronostico_SARIMA
```


##	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## Mar 2022	1380818	1214060	1547577	1125783.0	1635854
## Apr 2022	1407499	1225857	1589140	1129701.4	1685296
## May 2022	1634268	1447355	1821182	1348408.3	1920128
## Jun 2022	1764574	1574256	1954891	1473508.7	2055638
## Jul 2022	1592926	1399700	1786151	1297412.0	1888439
## Aug 2022	1611840	1415868	1807812	1312126.3	1911553
## Sep 2022	1499850	1301202	1698499	1196043.2	1803657
## Oct 2022	1352351	1151062	1553639	1044506.2	1660195
## Nov 2022	1552243	1348325	1756161	1240376.7	1864109

```

## Dec 2022      1465990 1259412 1672568 1150056.6 1781924
## Jan 2023      1393245 1184130 1602360 1073430.9 1713059
## Feb 2023      1227747 1016166 1439328  904161.1 1551333
## Mar 2023      1419191 1191212 1647171 1070526.3 1767856
## Apr 2023      1470241 1235731 1704752 1111588.3 1828894
## May 2023      1690637 1451647 1929628 1325133.3 2056142
## Jun 2023      1812779 1569876 2055683 1441290.0 2184269
## Jul 2023      1665925 1419304 1912546 1288750.8 2043099
## Aug 2023      1659841 1409595 1910086 1277122.8 2042558
## Sep 2023      1574109 1320297 1827921 1185936.9 1962281
## Oct 2023      1394608 1137267 1651949 1001039.4 1788176
## Nov 2023      1595162 1334294 1856030 1196198.6 1994125
## Dec 2023      1508910 1244433 1773387 1104426.9 1913393
## Jan 2024      1430061 1161934 1698187 1019996.1 1840125
## Feb 2024      1290753 1019387 1562118  875734.8 1705771
## Mar 2024      1467570 1187047 1748092 1038547.9 1896592
## Apr 2024      1523643 1237892 1809393 1086625.5 1960660
## May 2024      1742725 1452730 2032720 1299216.1 2186234
## Jun 2024      1863185 1569249 2157120 1413648.7 2312721
## Jul 2024      1721441 1423685 2019196 1266062.9 2176819
## Aug 2024      1710204 1408695 2011712 1249085.5 2171322
## Sep 2024      1629884 1324669 1935100 1163097.1 2096671
## Oct 2024      1443787 1134892 1752682  971373.5 1916201
## Nov 2024      1644477 1331888 1957066 1166413.3 2122541
## Dec 2024      1558225 1241812 1874638 1074313.1 2042137
## Jan 2025      1478118 1157654 1798582  988011.0 1968225
## Feb 2025      1344209 1020391 1668026  848971.7 1839445
## Mar 2025      1518010 1186447 1849574 1010927.2 2025094
## Apr 2025      1575119 1238668 1911570 1060561.4 2089676
## May 2025      1793931 1453344 2134517 1273048.3 2314813
## Jun 2025      1914043 1569560 2258527 1387201.1 2440885
## Jul 2025      1773353 1425070 2121636 1240699.6 2306006
## Aug 2025      1761053 1409025 2113081 1222673.0 2299434
## Sep 2025      1681850 1326115 2037585 1137800.0 2225899
## Oct 2025      1494393 1134970 1853816  944702.9 2044083
## Nov 2025      1695111 1331971 2058251 1139735.9 2250486
## Dec 2025      1608859 1241836 1975882 1047545.8 2170172
## Jan 2026      1528493 1157213 1899773  960669.2 2096316
## Feb 2026      1395696 1021068 1770324  822752.0 1968640
## Mar 2026      1568876 1186973 1950780  984805.0 2152948
## Apr 2026      1626198 1239549 2012847 1034869.0 2217527
## May 2026      1844954 1454235 2235673 1247400.9 2442507
## Jun 2026      1964995 1570421 2359569 1361546.2 2568444
## Jul 2026      1824522 1426179 2222864 1215309.2 2433734
## Aug 2026      1812003 1409940 2214067 1197100.1 2426907
## Sep 2026      1733030 1327277 2138783 1112484.1 2353575
## Oct 2026      1545293 1135863 1954723  919123.6 2171462
## Nov 2026      1746017 1332870 2159163 1114162.9 2377870
## Dec 2026      1659765 1242708 2076821 1021931.5 2297598
## Jan 2027      1579345 1157890 2000799  934786.0 2223904
## Feb 2027      1446777 1021996 1871559  797130.0 2096425

```

```
autoplot(Pronostico_SARIMA )
```

```
Pronostico_SARIMA <- data.frame(Pronostico_SARIMA)
Pronostico_SARIMA_ts <- ts(Pronostico_SARIMA$Point.Forecast, frequency = 12,
                           start = c(2022,3))
```

Unión de Pronósticos

```
## Warning in file(file, "rt"): no fue posible abrir el archivo 'Fechas_prediccion.csv':
## No such file or directory
## Error in file(file, "rt"): no se puede abrir la conexión
## Error in eval(expr, envir, enclos): objeto 'Fechaño encontrado
## Error in '[.data.frame'(Pronosticos_tabla, , c(5, 1:4)): undefined columns selected
##   Pronostico_Maiz_ETS_ts Pronostico_auto_Arima_ts Pronostico_H_W
## 1          1358901          1423619          1392310
## 2          1411741          1347140          1378603
## 3          1665017          1610709          1666292
## 4          1767237          1727214          1786091
```

## 5	1611548	1607550	1656689
## 6	1587120	1627400	1655248
## 7	1528756	1413268	1536163
## 8	1303272	1224287	1411248
## 9	1504711	1618009	1637760
## 10	1401595	1450403	1503188
## 11	1293426	1333857	1392782
## 12	1196922	1184494	1231961
## 13	1358901	1493725	1464221
## 14	1411741	1372176	1450514
## 15	1665017	1692395	1738203
## 16	1767237	1755726	1858002
## 17	1611548	1654394	1728600
## 18	1587120	1644273	1727160
## 19	1528756	1415615	1608074
## 20	1303272	1249748	1483159
## 21	1504711	1600349	1709671
## 22	1401595	1479456	1575099
## 23	1293426	1358424	1464693
## 24	1196922	1192241	1303872
## 25	1358901	1571503	1536132
## 26	1411741	1435830	1522425
## 27	1665017	1740677	1810114
## 28	1767237	1856671	1929913
## 29	1611548	1663751	1800511
## 30	1587120	1720707	1799071
## 31	1528756	1472273	1679985
## 32	1303272	1362601	1555070
## 33	1504711	1680545	1781582
## 34	1401595	1560807	1647010
## 35	1293426	1462968	1536604
## 36	1196922	1234952	1375783
## 37	1358901	1603006	1608044
## 38	1411741	1484223	1594336
## 39	1665017	1795247	1882025
## 40	1767237	1914947	2001824
## 41	1611548	1747605	1872422
## 42	1587120	1786661	1870982
## 43	1528756	1536459	1751896
## 44	1303272	1379542	1626981
## 45	1504711	1756073	1853493
## 46	1401595	1607299	1718921
## 47	1293426	1492011	1608515
## 48	1196922	1287149	1447694
## 49	1358901	1657897	1679955
## 50	1411741	1527649	1666247
## 51	1665017	1864814	1953936
## 52	1767237	1968969	2073735
## 53	1611548	1814849	1944333
## 54	1587120	1837606	1942893
## 55	1528756	1578388	1823807
## 56	1303272	1410701	1698893
## 57	1504711	1798056	1925404
## 58	1401595	1653114	1790832

## 59	1293426	1528563	1680426
## 60	1196922	1323357	1519605
##	Pronostico_SARIMA_ts		
## 1	1380818		
## 2	1407499		
## 3	1634268		
## 4	1764574		
## 5	1592926		
## 6	1611840		
## 7	1499850		
## 8	1352351		
## 9	1552243		
## 10	1465990		
## 11	1393245		
## 12	1227747		
## 13	1419191		
## 14	1470241		
## 15	1690637		
## 16	1812779		
## 17	1665925		
## 18	1659841		
## 19	1574109		
## 20	1394608		
## 21	1595162		
## 22	1508910		
## 23	1430061		
## 24	1290753		
## 25	1467570		
## 26	1523643		
## 27	1742725		
## 28	1863185		
## 29	1721441		
## 30	1710204		
## 31	1629884		
## 32	1443787		
## 33	1644477		
## 34	1558225		
## 35	1478118		
## 36	1344209		
## 37	1518010		
## 38	1575119		
## 39	1793931		
## 40	1914043		
## 41	1773353		
## 42	1761053		
## 43	1681850		
## 44	1494393		
## 45	1695111		
## 46	1608859		
## 47	1528493		
## 48	1395696		
## 49	1568876		
## 50	1626198		
## 51	1844954		

##	52	1964995
##	53	1824522
##	54	1812003
##	55	1733030
##	56	1545293
##	57	1746017
##	58	1659765
##	59	1579345
##	60	1446777

2.9.5. Gráfica de los pronósticos

